

# Лекция 4 Линейные модели классификации. Часть 1.

Кантонистова Е.О.

ВШЭ, 2018

# ОБУЧЕНИЕ ЛИНЕЙНОЙ РЕГРЕССИИ (НАПОМИНАНИЕ)

Обучающая выборка  $\{(x_i, y_i)\}, x_i \in \mathbb{R}^n, y_i \in \mathbb{R}$

- Модель линейной регрессии:

$$a(x, w) = (x, w) = \sum_{j=1}^n w_j x_j$$

- Функция потерь – квадратичная:

$$L(a, y) = (a - y)^2$$

- Метод обучения – метод наименьших квадратов:

$$Q(w) = \sum_{i=1}^n (a(x_i, w) - y_i)^2 \rightarrow \min$$

# БИНАРНАЯ КЛАССИФИКАЦИЯ

Обучающая выборка  $\{(x_i, y_i)\}, x_i \in \mathbb{R}^n, y_i \in \{-1, +1\}$


- Модель линейного классификатора:

$$a(x, w) = \text{sign}(x, w) = \text{sign}\left(\sum_{j=1}^n w_j x_j\right)$$

Уравнение

$$(x, w) = \sum_{j=1}^n w_j x_j = 0$$

– уравнение гиперплоскости  
с нормалью  $w$ .



# ОБУЧЕНИЕ КЛАССИФИКАТОРА

- Обучение - минимизация доли ошибок классификатора:

$$Q(a, X) = \frac{1}{l} \sum_{i=1}^l [a(x_i) \neq y_i] = \frac{1}{l} \sum_{i=1}^l [\text{sign}(w, x_i) \neq y_i] \rightarrow \min$$


Функционал  $Q$  можно переписать в виде:

$$Q(a, X) = \frac{1}{l} \sum_{i=1}^l [y_i \cdot (w, x_i) < 0] = \frac{1}{l} \sum_{i=1}^l [M_i < 0] \rightarrow \min$$

- $M_i = y_i \cdot (w, x_i)$  - **отступ**


# ОТСТУП (MARGIN)

- Знак отступа  $M$  говорит о корректности классификации ( $M > 0$  – объект классифицирован верно,  $M < 0$  – неверно)
- Абсолютная величина отступа  $M$  обозначает степень уверенности классификатора в ответе (чем ближе  $M$  к нулю, тем меньше уверенность в ответе)



# ОТСТУП (MARGIN)

Ранжирование объектов по возрастанию отступа:



# ОБУЧЕНИЕ КЛАССИФИКАТОРА

Обучающая выборка  $\{(x_i, y_i)\}, x_i \in \mathbb{R}^n, y_i \in \{-1, +1\}$

- Модель линейного классификатора:

$$a(x, w) = \text{sign}(x, w) = \text{sign}\left(\sum_{j=1}^n w_j x_j\right)$$

- Функция потерь – бинарная:

$$L(a, y) = [a \neq y] = [a \cdot y < 0]$$

- Метод обучения – минимизация эмпирического риска:

$$Q(a, X) = \frac{1}{l} \sum_{i=1}^l [y_i \cdot (w, x_i) < 0] \rightarrow \min$$

# ВЕРХНИЕ ОЦЕНКИ ЭМПИРИЧЕСКОГО РИСКА

- $L(a, y) = L(M) = [M < 0]$  – разрывная функция потерь

Оценим

$L(M) \leq \tilde{L}(M)$ , где  $\tilde{L}(M)$  - непрерывная или гладкая функция потерь.

- Тогда


$$Q(a, X) = \frac{1}{l} \sum_{i=1}^l L(y_i \cdot (w, x_i)) \leq \frac{1}{l} \sum_{i=1}^l \tilde{L}(y_i \cdot (w, x_i)) \rightarrow \min$$



# ФУНКЦИИ ПОТЕРЬ

- $L(M) = \log(1 + e^{-M})$  – логистическая функция потерь
- $V(M) = (1 - M)_+ = \max(0, 1 - M)$  – кусочно-линейная функция потерь (SVM)
- $H(M) = (-M)_+ = \max(0, -M)$  – кусочно-линейная функция потерь (персептрон)
- $E(M) = e^{-M}$  - экспоненциальная функция потерь
- $S(M) = \frac{2}{1 + e^{-M}}$  - сигмоидная функция потерь
- $[M < 0]$  – пороговая функция потерь

# ФУНКЦИИ ПОТЕРЬ



# ОПТИМИЗАЦИЯ ФУНКЦИОНАЛА ПОТЕРЬ

- Нахождение минимума функции потерь происходит с помощью метода градиентного спуска:

$$w^{(k)} = w^{(k-1)} - \eta_k \nabla Q(w^{(k-1)})$$

# МЕТРИКИ КАЧЕСТВА КЛАССИФИКАЦИИ

- Accuracy – доля правильных ответов:

$$accuracy(a, X) = \frac{1}{l} \sum_{i=1}^l [a(x_i) = y_i]$$

Недостаток: при сильно несбалансированной выборке не отражает качество работы алгоритма

# МАТРИЦА ОШИБОК

Матрица ошибок (confusion matrix):

		Actual Value	
		positives	negatives
Predicted Value	positives	<b>TP</b> True Positive	<b>FP</b> False Positive
	negatives	<b>FN</b> False Negative	<b>TN</b> True Negative

$$accuracy = (TP + TN) / (TP + FP + FN + TN)$$

# МЕТРИКИ КАЧЕСТВА КЛАССИФИКАЦИИ: PRECISION, RECALL

- **Precision (точность):**

$$\textit{Precision}(a, X) = \frac{TP}{TP + FP}$$

Показывает, насколько можно доверять классификатору при  $a(x) = 1$

# PRECISION: ПРИМЕР

Модель  $a_1(x)$ :

$$\text{precision}(a_1, X) = 0.8$$

Модель  $a_2(x)$ :

$$\text{precision}(a_2, X) = 0.96$$

	$y = 1$ Могут вернуть	$y = -1$ Не могут вернуть
$a(x) = 1$ Получили кредит	80	20
$a(x) = -1$ Не получили кредит	20	80

	$y = 1$ Могут вернуть	$y = -1$ Не могут вернуть
$a(x) = 1$ Получили кредит	48	2
$a(x) = -1$ Не получили кредит	52	98

# МЕТРИКИ КАЧЕСТВА КЛАССИФИКАЦИИ: PRECISION, RECALL

- Precision (точность):

$$\textit{Precision}(a, X) = \frac{TP}{TP + FP}$$

Показывает, насколько можно доверять классификатору при  $a(x) = 1$

- Recall (полнота):

$$\textit{Recall}(a, X) = \frac{TP}{TP + FN}$$

Показывает, как много объектов положительного класса находит классификатор



# RECALL: ПРИМЕР

Модель  $a_1(x)$ :

$$\text{recall}(a_1, X) = 0.8$$


	$y = 1$ Могут вернуть	$y = -1$ Не могут вернуть
$a(x) = 1$ Получили кредит	80	20
$a(x) = -1$ Не получили кредит	20	80

Модель  $a_2(x)$ :

$$\text{recall}(a_2, X) = 0.48$$

	$y = 1$ Могут вернуть	$y = -1$ Не могут вернуть
$a(x) = 1$ Получили кредит	48	2
$a(x) = -1$ Не получили кредит	52	98

# ТОЧНОСТЬ И ПОЛНОТА




$$\text{Precision} = \frac{\text{true positives}}{\text{true positives} + \text{false positives}}$$

$$\text{Recall} = \frac{\text{true positives}}{\text{true positives} + \text{false negatives}}$$

# F-МЕРА

F-мера – это метрика качества, учитывающая и точность, и полноту

$$F(a, X) = \frac{2 \cdot \textit{Precision} \cdot \textit{Recall}}{\textit{Precision} + \textit{Recall}}$$



# КАК РЕГУЛИРОВАТЬ ТОЧНОСТЬ И ПОЛНОТУ

Обобщенная форма записи классификатора:

$$a(x) = [b(x) > t], t \in \mathbb{R}$$

В случае линейного классификатора

$$a(x) = [(w, x) > 0],$$

$$b(x) = (w, x), t = 0$$

- Регулировать точность и полноту можно путем изменения порога  $t$ .

# ИНТЕГРАЛЬНАЯ МЕТРИКА: ROC-AUC

Хотим измерить качество всего семейства классификаторов

$$a(x) = [b(x) > t], t \in \mathbb{R}$$

(без фиксации порога  $t$ ).

Для этого будем использовать метрику AUC

**AUC** – *Area Under ROC Curve* (площадь под ROC-кривой)

# ROC-КРИВАЯ

Для каждого значения порога  $t$  вычислим:

- False Positive Rate (доля неверно принятых объектов):


$$FPR = \frac{FP}{FP+TN} = \frac{\sum_i [y_i = -1][a(x_i) = +1]}{\sum_i [y_i = -1]}$$

- True Positive Rate (доля верно принятых объектов):

$$TPR = \frac{TP}{TP+FN} = \frac{\sum_i [y_i = +1][a(x_i) = +1]}{\sum_i [y_i = +1]}.$$

		Actual Values	
		Positive (1)	Negative (0)
Predicted Values	Positive (1)	TP	FP
	Negative (0)	FN	TN

# ROC-КРИВАЯ




# ROC-КРИВАЯ. AUC.

- Каждая точка на ROC-кривой соответствует классификатору с фиксированным значением порога  $t$ .
- Всего различных порогов  $l + 1$ , где  $l$  – количество объектов.

AUC – площадь под ROC-кривой.  $AUC \in [0; 1]$

- $AUC = 1$  –  
идеальная классификация
- $AUC = 0.5$  –  
случайная классификация





# ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

- Пусть есть выборка из 5 объектов и следующие предсказания классификатора оценки принадлежности к классу +1:

$b(x)$	0.2	0.4	0.1	0.7	0.05
$y$	-1	+1	-1	+1	+1

# ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

- Пусть есть выборка из 5 объектов и следующие предсказания классификатора оценки принадлежности к классу +1:

$b(x)$	0.2	0.4	0.1	0.7	0.05
$y$	-1	+1	-1	+1	+1

- Упорядочим объекты по убыванию предсказаний:  
(0.7, 0.4, 0.2, 0.1, 0.05)

**1 шаг:  $t = 0.7$ , то есть**

$$a(x) = [b(x) > 0.7]$$

$$TPR = \frac{TP}{TP+FN}$$

$$FPR = \frac{FP}{FP+TN}$$

# ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

- Пусть есть выборка из 5 объектов и следующие предсказания классификатора оценки принадлежности к классу +1:

$b(x)$	0.2	0.4	0.1	0.7	0.05
$y$	-1	+1	-1	+1	+1

- Упорядочим объекты по убыванию предсказаний: (0.7, 0.4, 0.2, 0.1, 0.05)

**1 шаг:  $t = 0.7$ , то есть**

$$a(x) = [b(x) > 0.7]$$

$$TPR = \frac{0}{0+3} = 0, \quad FPR = \frac{0}{0+2} = 0.$$

$$TPR = \frac{TP}{TP+FN}$$

$$FPR = \frac{FP}{FP+TN}$$

# ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

- Пусть есть выборка из 5 объектов и следующие предсказания классификатора оценки принадлежности к классу +1:

$b(x)$	0.2	0.4	0.1	0.7	0.05
$y$	-1	+1	-1	+1	+1


- Упорядочим объекты по убыванию предсказаний:  
(0.7, 0.4, 0.2, 0.1, 0.05)

**1 шаг:**  $t = 0.7$ , то есть

$$a(x) = [b(x) > 0.7]$$

$$TPR = \frac{0}{0+3} = 0,$$

$$FPR = \frac{0}{0+2} = 0.$$



# ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

- Оценки принадлежности к классу +1:


$b(x)$	0.2	0.4	0.1	0.7	0.05
$y$	-1	+1	-1	+1	+1

- Упорядочим объекты по убыванию предсказаний:  
(0.7, 0.4, 0.2, 0.1, 0.05)

**2 шаг:**  $t = 0.4$ , то есть  
 $a(x) = [b(x) > 0.4]$

$$TPR = \frac{1}{1+2} = \frac{1}{3},$$

$$FPR = \frac{0}{0+2} = 0.$$



# ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

- Оценки принадлежности к классу +1:

$b(x)$	0.2	0.4	0.1	0.7	0.05
$y$	-1	+1	-1	+1	+1

- Упорядочим объекты по

убыванию предсказаний:


(0.7, 0.4, 0.2, 0.1, 0.05)

**3 шаг:**  $t = 0.2$ , то есть

$$a(x) = [b(x) > 0.2]$$

$$TPR = \frac{2}{2+1} = \frac{2}{3},$$

$$FPR = \frac{0}{0+2} = 0.$$



# ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

- Оценки принадлежности к классу +1:


$b(x)$	0.2	0.4	0.1	0.7	0.05
$y$	-1	+1	-1	+1	+1

- Упорядочим объекты по убыванию предсказаний:  
(0.7, 0.4, 0.2, 0.1, 0.05)

**4 шаг:**  $t = 0.1$ , то есть  
 $a(x) = [b(x) > 0.1]$

$$TPR = \frac{2}{2+1} = \frac{2}{3},$$

$$FPR = \frac{1}{1+1} = \frac{1}{2}.$$



# ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

- Оценки принадлежности к классу +1:


$b(x)$	0.2	0.4	0.1	0.7	0.05
$y$	-1	+1	-1	+1	+1

- Упорядочим объекты по убыванию предсказаний:  
(0.7, 0.4, 0.2, 0.1, 0.05)

**5 шаг:**  $t = 0.05$ , то есть  
 $a(x) = [b(x) > 0.05]$

$$TPR = \frac{2}{2+1} = \frac{2}{3},$$

$$FPR = \frac{2}{2+0} = 1.$$





# ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

- Оценки принадлежности к классу +1:

$b(x)$	0.2	0.4	0.1	0.7	0.05
$y$	-1	+1	-1	+1	+1

- Упорядочим объекты по

убыванию предсказаний:


(0.7, 0.4, 0.2, 0.1, 0.05)

**5 шаг:**  $t = 0$ , то есть

$$a(x) = [b(x) > 0]$$


$$TPR = \frac{3}{3+0} = 1,$$

$$FPR = \frac{2}{2+0} = 1.$$



# ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

$$AUC = 2/3$$




# ИНДЕКС ДЖИНИ

Индекс Джини:

$$Gini = 2 \cdot AUC - 1$$


- Индекс Джини – это удвоенная площадь между главной диагональю и ROC-кривой.



# PRECISION-RECALL КРИВАЯ

- В случае малой доли объектов положительного класса AUC-ROC может давать неадекватно хороший результат


Precision-Recall кривая:

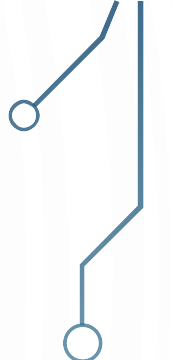
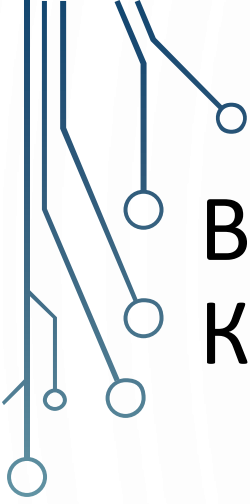


# AUC-PR

AUC-PR – площадь под PR-кривой


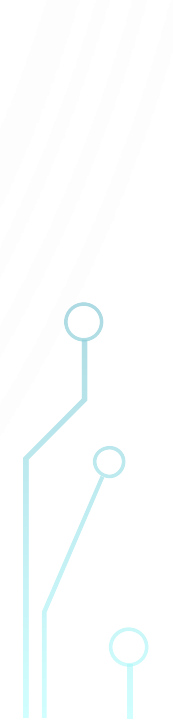
Precision-Recall example: AUC=0.79





# ВИДЫ ЛИНЕЙНЫХ КЛАССИФИКАТОРОВ

В этой лекции:

- Персептрон
  - Логистическая регрессия (начало)
- 
- 

# ПЕРСЕПТРОН РОЗЕНБЛАТТА


- Задача классификации с двумя классами  $y_i \in \{0,1\}$
- Признаки объектов – бинарные:  $x_i^j \in \{0,1\}$

Алгоритм:  $a(x, w) = [w_1 x_1 + \dots + w_n x_n > 0] = [(w, x) > 0]$

# ПЕРСЕПТРОН РОЗЕНБЛАТТА

- Задача классификации с двумя классами  $y_i \in \{0,1\}$
- Признаки объектов – бинарные:  $x_i^j \in \{0,1\}$

Алгоритм:  $a(x, w) = [w_1 x_1 + \dots + w_n x_n > 0] = [(w, x) > 0]$





# ПЕРСЕПТРОН РОЗЕНБЛАТТА

- Задача классификации с двумя классами  $y_i \in \{0,1\}$
- Признаки объектов – бинарные:  $x_i^j \in \{0,1\}$

Алгоритм:  $a(x, w) = [(w, x) > 0]$

Обучение алгоритма, правило Хебба (исправление весов в случае ошибки):

- $a(x_i, w) = y_i \Rightarrow w$  менять не нужно
- $a(x_i, w) = 0, y_i = 1 \Rightarrow w_j := w_j + h \cdot x_i^j$
- $a(x_i, w) = 1, y_i = 0 \Rightarrow w_j := w_j - h \cdot x_i^j$

# ПЕРСЕПТРОН РОЗЕНБЛАТТА

- Задача классификации с двумя классами  $y_i \in \{0,1\}$
- Признаки объектов – бинарные:  $x_i^j \in \{0,1\}$

Алгоритм:  $a(x, w) = [(w, x) > 0]$


Обучение алгоритма (исправление весов в случае ошибки):

- $a(x_i, w) = y_i \Rightarrow w$  менять не нужно
- $a(x_i, w) = 0, y_i = 1 \Rightarrow w_j := w_j + h \cdot x_i^j$
- $a(x_i, w) = 1, y_i = 0 \Rightarrow w_j := w_j - h \cdot x_i^j$

Общая формула коррекции весов:


$$w := w - h(a(x_i, w) - y_i)x_i$$

# ПРИМЕР: РЕАЛИЗАЦИЯ ЛОГИЧЕСКОГО AND С ПОМОЩЬЮ ПЕРСЕПТРОНА

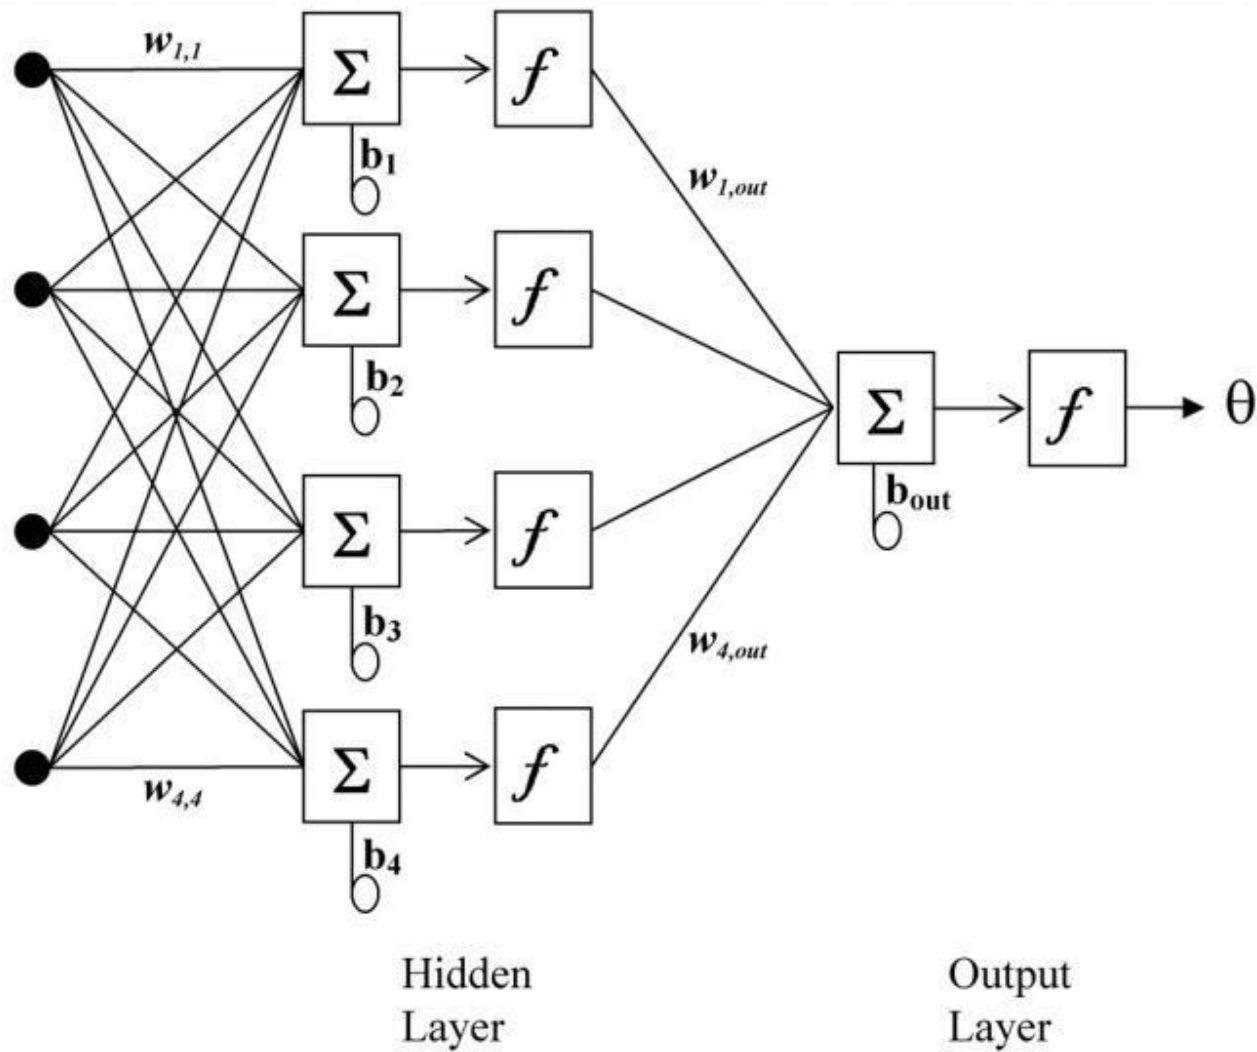


# ПРИМЕР: РЕАЛИЗАЦИЯ ЛОГИЧЕСКОГО AND С ПОМОЩЬЮ ПЕРСЕПТРОНА

$$a(x, w) = \text{sign}(x_1 + x_2 - 1.5)$$



# ПРИМЕР ДВУХСЛОЙНОГО ПЕРСЕПТРОНА



# ЛОГИСТИЧЕСКАЯ РЕГРЕССИЯ

Хотим предсказывать не классы, а вероятности классов.

- Линейная регрессия:  $a(x, w) = (x, w) = w^T x \in \mathbb{R}$
- Логистическая регрессия:  $a(x, w) = g(w^T x)$ ,

где  $g(z) = \frac{1}{1+e^{-z}}$  - сигмоида (логистическая функция)


# ЛОГИСТИЧЕСКАЯ РЕГРЕССИЯ

Хотим предсказывать не классы, а вероятности классов.

- Линейная регрессия:  $a(x, w) = (x, w) = w^T x \in \mathbb{R}$
- Логистическая регрессия:  $a(x, w) = g(w^T x)$ ,

где  $g(z) = \frac{1}{1+e^{-z}}$  - сигмоида (логистическая функция),

$g(z) \in (0; 1)$ .



Логистическая регрессия:  $a(x, w) = \frac{1}{1+e^{-w^T x}}$

# ВЕРОЯТНОСТНЫЙ СМЫСЛ


- $a(x, w)$  – вероятность того, что  $y = +1$  на объекте  $x$  (см. следующую лекцию), т.е.

$$a(x, w) = P(y = +1|x; w)$$



# РАЗДЕЛЯЮЩАЯ ГРАНИЦА

Предсказываем  $y = +1$ , если  $a(x, w) \geq 0.5$ .



$a(x, w) = g(w^T x) \geq 0.5$ , если  $w^T x \geq 0$ .

Получаем, что

- $y = +1$  при  $w^T x \geq 0$
- $y = -1$  при  $w^T x < 0$ ,

т.е.  $w^T x = 0$  – разделяющая гиперплоскость.

# ЛОГИСТИЧЕСКАЯ РЕГРЕССИЯ

**Логистическая регрессия - это линейный классификатор!**

# ФУНКЦИЯ ПОТЕРЬ ЛОГИСТИЧЕСКОЙ РЕГРЕССИИ

Если взять квадратичную функцию потерь

$$L(a, y) = (a - y)^2,$$


то возникнут проблемы:

- $Q(a, X) = \frac{1}{l} \sum_{i=1}^l \left( \frac{1}{1 + e^{-w^T x}} - y \right)^2$  - не выпуклая функция (можем не попасть в глобальный минимум при оптимизации)
- На совсем неправильном предсказании маленький штраф (пусть предсказали вероятность 0% на объекте класса  $y = +1$ , тогда штраф всего  $(1 - 0)^2 = 1$ )


# ФУНКЦИЯ ПОТЕРЬ ЛОГИСТИЧЕСКОЙ РЕГРЕССИИ

Возьмем логистическую функцию потерь (log-loss):

$$Q(w) = - \sum_{i=1}^l ([y_i = +1] \cdot \log(a(x_i, w)) + [y_i = -1] \cdot \log(1 - a(x_i, w)))$$



# ЛОГИСТИЧЕСКАЯ ФУНКЦИЯ ПОТЕРЬ



- если  $a(x, w) = 1$  и  $y = +1$ , то штраф  $L(a, y) = 0$
- если  $a(x, w) \rightarrow 0$ , а  $y = +1$ , то штраф  $L(a, y) \rightarrow +\infty$